



Scikit-Learn Agentic RAG Agent.

Σταματίνα Σοφρώνη

A.M.: 25116

Εφαρμογές Επιστήμης των Δεδομένων και Τεχνητής Νοημοσύνης.



Πρόβλημα & Στόχος.

- Το scikit-learn documentation είναι μεγάλο και τεχνικό.
- Ο χρήστης χρειάζεται γρήγορες, τεκμηριωμένες απαντήσεις από επίσημες πηγές.
- Στόχος: ανάπτυξη ενός Agentic RAG συστήματος που απαντά σε ερωτήσεις για supervised classification workflows.

Αντί το LLM να απαντά μόνο από γενικές γνώσεις, πρώτα ανακτά σχετικά αποσπάσματα από το scikit-learn documentation και μετά παράγει grounded απάντηση.



Corpus: scikit-learn documentation.

- 10 επιλεγμένες σελίδες από το επίσημο scikit-learn documentation.
- Θεματικό πεδίο: supervised classification workflows.
- Καλύπτει preprocessing, pipelines, train/test split, cross-validation, hyperparameter tuning, metrics, Logistic Regression και RandomForestClassifier.
- Υποστηρίζει conceptual, procedural και decision-support ερωτήσεις.

Γιατί αυτό το corpus;

Είναι επίσημο, τεχνικό, δομημένο και αρκετά πλούσιο για ουσιαστικό RAG pipeline.



Αρχιτεκτονική Συστήματος.

Scikit-learn docs → Ingestion & Chunking → Embeddings → Qdrant Vector Store → Retriever → Grounded LLM Answer → Agent Layer

- Embeddings: text-embedding-3-small
- Vector store: Qdrant
- Generation: gpt-4.1-mini

Agent layer:

rule-based baseline + LangGraph ReAct agent



Ingestion & Chunking Strategies.

v1_fixed

- Fixed-size chunking
- Σταθερό μέγεθος chunks
- Overlap μεταξύ chunks
- 402 chunks

v2_structured

- Section-based chunking
- Βασισμένο σε headings / sections
- Καλύτερη νοηματική συνοχή
- 375 chunks

Το v2_structured είχε καλύτερα retrieval αποτελέσματα, ειδικά στο top-1.



Metadata Schema & Retrieval Tools.

Metadata ανά chunk

- doc_id
- title
- topic
- url
- section
- chunking_strategy

Retrieval tools

1. rag_retriever
Αναζήτηση σε όλο το corpus
2. metadata_filtered_retriever
Αναζήτηση με topic filter

Q: Which RandomForestClassifier parameters control complexity?

→ topic_filter = random_forest_classifier

→ ανάκτηση από D10



RAG Pipeline.

User question

→ Embedding

→ Qdrant search

→ Retrieved chunks

→ Context

→ LLM answer

→ Sources

- Το LLM απαντά μόνο με βάση το ανακτημένο context.
- Αν η πληροφορία δεν υπάρχει στο corpus, το σύστημα πρέπει να το δηλώσει.
- Στόχος: μείωση hallucinations και grounded απαντήσεις.



Agent Architecture.

Rule Based Agent

- Baseline agent
- Επιλογή tool με κανόνες / keywords
- Σταθερός και προβλέψιμος
- Χρήσιμος ως fallback

Tools:

rag_retriever + metadata_filtered_retriever

LangGraph ReAct Agent

- Improved agentic version
- LLM-based tool selection
- Χρησιμοποιεί τα ίδια retrieval tools
- Υποστηρίζει hybrid mode



Live Demo.

Demo goal:

Να δείξω ότι το σύστημα ανακτά context, επιλέγει tool και παράγει grounded απάντηση.

Representative questions:

1. General workflow question → rag_retriever
2. API-specific question → metadata_filtered_retriever
3. Out-of-context question → grounding / refusal

Q1: How can a complete classification workflow combine preprocessing, model training, cross-validation and evaluation?

Q2: Which RandomForestClassifier parameters can control model complexity?

Q3: Who won the FIFA World Cup in 2022?



```
python src/agent/langgraph_agent.py --question "Which RandomForestClassifier parameters can control model complexity?"
```



Αποτελέσματα Αξιολόγησης.

Metric	v1_fixed	v2_structured
Expected source in top-k	93.33%	96.67%
Expected source top-1	73.33%	80.00%

- To structured chunking είχε καλύτερη retrieval επίδοση.
- To metadata filtering βελτίωσε API-specific ερωτήσεις, όπως το Q28.
- Tool Call Accuracy: 100% στον rule-based baseline agent.



HAIC Benchmarking.

- Χρησιμοποιήθηκε professor-style HAIC artifact:
`haic.decisions_artifact.v1`
- 30 sessions / 150 logged events
- Βασικές μετρικές:
EL = 0.000
Tr = 0.967
HCL = 0.883
EfficiencyScore = 1.000

Limitation:

To accept/reject υπολογίστηκε offline με proxy και όχι από πραγματικό user study.

Comparison with Existing scikit-learn RAG Prototype.

Σημείο	Probabl / scikit-learn RAG	Δικό μου project
Στόχος	Βελτιωμένη αναζήτηση στο scikit-learn documentation	Agentic RAG για supervised classification workflows
Corpus	Ευρύτερο scikit-learn documentation	10 curated σελίδες για classification workflows
Chunking	Διαφορετικές στρατηγικές για API docs, examples, user guide	Σύγκριση v1_fixed και v2_structured
Retrieval	BM25 + SBERT / neural retrieval + reranking	OpenAI embeddings + Qdrant vector search
LLM	Mistral 7B local/quantized	gpt-4.1-mini
Metadata filtering	Έμφαση σε structured chunks/ambiguity	Explicit metadata_filtered_retriever με topic filter

Η Probabl περιγράφει το RAG ως “**improved search bar**” και μάλιστα λέει ότι δεν θέλουν back-and-forth conversational agent, αλλά φυσική ερώτηση → απάντηση.



Limitations & Επόμενα Βήματα.

Limitations

- Περιορισμένο corpus: 10 scikit-learn pages
- HAIC χωρίς πραγματικό user study
- Langfuse σε demo-level integration
- Docker μόνο για Qdrant, όχι πλήρες app containerization


Επόμενα βήματα

- Επέκταση corpus σε περισσότερες σελίδες
- Πλήρες Dockerfile για την Python εφαρμογή
- Πραγματικό user study για HAIC
- Καλύτερο Langfuse tracing σε όλο το agent flow



Συμπέρασμα.

- Υλοποιήθηκε ένα ολοκληρωμένο Agentic RAG σύστημα για το scikit-learn documentation.
- Το v2_structured chunking βελτίωσε την ανάκτηση σε σχέση με το v1_fixed.
- Το σύστημα συνδυάζει RAG pipeline, metadata filtering, agent routing, αξιολόγηση και HAIC benchmarking.
- Ο LangGraph ReAct agent προστέθηκε ως πιο agentic εκδοχή πάνω από τον rule-based baseline.



Thank you — Questions?