



Scikit-Learn Agentic RAG Agent.

Σταματίνα Σοφρώνη

A.M.: 25116

Εφαρμογές Επιστήμης των Δεδομένων και Τεχνητής Νοημοσύνης.



Πρόβλημα & Στόχος.

- Το scikit-learn documentation είναι μεγάλο και τεχνικό.
- Ο χρήστης χρειάζεται γρήγορες, τεκμηριωμένες απαντήσεις από επίσημες πηγές.
- Στόχος: ανάπτυξη ενός Agentic RAG συστήματος που απαντά σε ερωτήσεις για supervised classification workflows.

➡ Αντί το LLM να απαντά μόνο από γενικές γνώσεις, πρώτα ανακτά σχετικά αποσπάσματα από το scikit-learn documentation και μετά παράγει grounded απάντηση.



Corpus: scikit-learn documentation.

- 10 επιλεγμένες σελίδες από το επίσημο scikit-learn documentation.
- Θεματικό πεδίο: supervised classification workflows.
- Καλύπτει preprocessing, pipelines, train/test split, cross-validation, hyperparameter tuning (evaluation metrics), Logistic Regression και RandomForestClassifier.
- Υποστηρίζει εννοιολογικές, πρακτικές και decision-support ερωτήσεις.

Γιατί αυτό το corpus;

Είναι επίσημο, τεχνικό, δομημένο και αρκετά πλούσιο για ουσιαστικό RAG pipeline.



Αρχιτεκτονική Συστήματος.

Scikit-learn documentation → Ingestion & Chunking → Embeddings → Qdrant Vector Store → Retriever → Grounded LLM Answer → Agent Layer

- Embeddings: text-embedding-3-small
- Vector store: Qdrant
- Generation: gpt-4.1-mini

Agent layer:

rule-based baseline + LangGraph ReAct agent



Ingestion & Chunking Strategies.

v1_fixed

- Fixed-size chunking
- Σταθερό μέγεθος chunks
- Overlap μεταξύ chunks
- 402 chunks

v2_structured

- Section-based chunking
- Βασισμένο σε headings / sections
- Καλύτερη νοηματική συνοχή
- 375 chunks



Metadata Schema & Retrieval Tools.

Κάθε chunk δεν αποθηκεύεται μόνο ως κείμενο, αλλά και με metadata.

Metadata ανά chunk

- doc_id
- title
- topic
- url
- section
- chunking_strategy

Retrieval tools

1. rag_retriever:

Αναζήτηση γενικά σε όλο το corpus (όταν η ερώτηση είναι γενική).

2. metadata_filtered_retriever:

Αναζήτηση με φίλτρο σε συγκεκριμένο topic.

Q: Which RandomForestClassifier parameters control complexity?

→ topic_filter = random_forest_classifier

→ ανάκτηση από D10



RAG Pipeline.

Η βασική ροή του συστήματος.

To user question

- Μετατρέπεται σε Embedding
- Χρησιμοποιείται για semantic search στο Qdrant
- Retrieved chunks
- Μετατροπή σε Context
- LLM answer
- Επιστροφή των Sources

- Το LLM απαντά μόνο με βάση το ανακτημένο context.
- Αν η πληροφορία δεν υπάρχει στο corpus, το σύστημα πρέπει να το δηλώσει.
- Στόχος: μείωση hallucinations και grounded απαντήσεις.



Agent Architecture.

Rule Based Agent

- Baseline agent
- Σταθερός και προβλέψιμος
- Εάν η ερώτηση δεν διατυπωθεί σωστά μπορεί να μην πιάσει το σωστό keyword.

Tools:

rag_retriever + metadata_filtered_retriever

LangGraph ReAct Agent

- Καταλαβαίνει καλύτερα φυσική γλώσσα
- Μπορεί να επιλέξει εργαλείο πιο εύκολα
- Λιγότερο προβλέψιμος από rule-based
- Υποστηρίζει hybrid mode (συνδυάζει την πιο σταθερή λογική του rule-based μηχανισμού, με την πιο ευέλικτη λογική του LLM-based agent.



Live Demo.

Demo goal:

Να δείξω ότι το σύστημα ανακτά context, επιλέγει tool και παράγει grounded απάντηση.

Representative questions:

1. General workflow question → rag_retriever
2. API-specific question → metadata_filtered_retriever
3. Out-of-context question → grounding / refusal

Q1: How can a complete classification workflow combine preprocessing, model training, cross-validation and evaluation?

Q2: Which RandomForestClassifier parameters can control model complexity?

Q3: Who won the FIFA World Cup in 2022?

➡ docker compose up
➡ cat outputs/docker_demo_run.md



Αποτελέσματα Αξιολόγησης.

Metric	v1_fixed	v2_structured
Expected source in top-k	93.33%	96.67%
Expected source top-1	73.33%	80.00%

- To structured chunking είχε καλύτερη retrieval επίδοση.
- To metadata filtering βελτίωσε API-specific ερωτήσεις.
- Tool Call Accuracy: 100% στον rule-based baseline agent.



HAIC Benchmarking.

- Χρησιμοποιήθηκε professor-style HAIC artifact:
`haic.decisions_artifact.v1`
- 30 sessions (δοκιμές) / 150 logged events
- Βασικές μετρικές:
EL = 0.000
Tr = 0.967
HCL = 0.883
EfficiencyScore = 1.000

Limitation:

Το accept/reject υπολογίστηκε offline με proxy (χρησιμοποίησε μετρήσιμα κριτήρια ως υποκατάστατο ανθρώπινης αξιολόγησης) και όχι από πραγματικό user study.

Δηλαδή: Το σύστημα βλέπει ότι η απάντηση έχει σωστή πηγή, είναι σχετική και συμφωνεί με την expected answer, άρα την μετράει ως “accepted”.

Comparison with Existing scikit-learn RAG Prototype.

Σημείο	Probabl / scikit-learn RAG	Δικό μου project
Στόχος	Βελτιωμένη αναζήτηση στο scikit-learn documentation	Agentic RAG για supervised classification workflows
Corpus	Ευρύτερο scikit-learn documentation	10 curated σελίδες για classification workflows
Chunking	Διαφορετικές στρατηγικές για API docs, examples, user guide	Σύγκριση v1_fixed και v2_structured
Retrieval	BM25 + SBERT / neural retrieval + reranking	OpenAI embeddings + Qdrant vector search
LLM	Mistral 7B local/quantized	gpt-4.1-mini
Metadata filtering	Έμφαση σε structured chunks/ambiguity	Explicit metadata_filtered_retriever με topic filter

Η Probabl περιγράφει το RAG ως “**improved search bar**”. Δεν θέλουν back-and-forth conversational agent, αλλά φυσική ερώτηση → απάντηση.



Limitations & Επόμενα Βήματα.

Limitations

- Περιορισμένο corpus: 10 scikit-learn pages
- HAIC χωρίς πραγματικό user study
- Το Langfuse tracing έχει υλοποιηθεί για αντιπροσωπευτικά RAG και agent runs, αλλά όχι για κάθε batch evaluation script.
- Dockerized Qdrant + Python demo service, αλλά όχι πλήρες interactive UI/API.


Επόμενα βήματα

- Επέκταση corpus σε περισσότερες σελίδες.
- Πλήρες Dockerfile για την Python εφαρμογή.
- Ανάπτυξη πλήρους interactive UI/API για το σύστημα.
- Επέκταση Langfuse tracing σε όλα τα batch evaluation scripts.



Συμπέρασμα.

- Υλοποιήθηκε ένα ολοκληρωμένο Agentic RAG σύστημα για το scikit-learn documentation.
- Το v2_structured chunking βελτίωσε την ανάκτηση σε σχέση με το v1_fixed.
- Το σύστημα συνδυάζει RAG pipeline, metadata filtering, agent routing, αξιολόγηση και HAIC benchmarking.
- Ο LangGraph ReAct agent προστέθηκε ως πιο agentic εκδοχή πάνω από τον rule-based baseline.



Thank you — Questions?